MongoDB: MapReduces, Optimisations et performances

Sommaire

- 1. MapReduce
- 2. Les index
- 3. Optimisations et performances
- 4. MongoDB Compass
- 5. Nouveautés MongoDB 3.6

I - MapReduces

Introduction

- Limites de aggregate
- Copie des données transformées dans une autre collection
- traitement plus rapide
- fonctions pure JS

Utilisation

```
db.collection.mapReduce(
   function() {emit(key,value);},
   function(key,values) {return reduceFunction},
   {
     out: collection,
     query: document,
     sort: document,
     limit: number,
     finalize : function
   }
)
```

3 Paramètres:

- map: Fonction javascript qui mappe une valeur à une clé et emet la paire clé/valeur via la fonction emit(key, value)
- reduce: Fonction javascript qui réduit ou regroupe tout les documents ayant la même clé
- options : Objet contenant les options de fonctionnement du mapReduce

Options:

- out: Spécifie l'emplacement du résulat du mapReduce.
- query: Précise les critères de sélection
- sort: Précise les critères de tri
- limit: Indique le nombre maximal de documents à retourner
- finalize : Fonction permettant de modifier la valeur retournée par le reduce.

Exemple : Affichage du nombre de films par genre depis la collection suivante :

```
{
   nom : "nom du film",
   genre : "genre du film"
}
```

Réponse:

```
var map = function() {
    emit(this.genre, 1);
};
var reduce = function(key, values) {
    return Array.sum(values)
};
var count = db.movies.mapReduce(map, reduce, {
    out: "movies result"
});
>db.movies result.find();
```

Exlications:

- Pour chaque film, dans la fonction map, on prend comme clé le genre du film et comme valeur 1 pour dire qu'on a un film de ce genre.
- Dans la fonction reduce, on dit qu'on fait un SUM de toutes les valeurs correspondant à un genre (donc tous les 1 retournés pour ce genre).
- On dit qu'on met le résultat dans la collection movies_result
- On affiche le contenu de movies_result

Bien:

- Gain de temps: La requête du mapReduce n'est faite qu'une seule fois. pour voir le résultat plus tard, vous devrez juste regarder la collection contenant le résultat.
- Simple : Tout marche par groupe de clé/valeur

Pas bien:

- Trop simple : Comment ça se passe si on veut travailler sur plusieures clés en même temps ?
- Temps réel: Comment faire pour avoir les résultats qui se mettent automatiquement à jour dans la table résultat ?

Travailler sur plusieurs clés

- le emit() peut être appelé autant de fois que necessaire dans la fonction map.
- Vous pouvez très bien faire des groupement de if, while, for,
 ... dans vos différentes fonctions vu que c'est du JS.
- emit(key, value) peut prendre un objet pour le paramètre value.

Nous verrons comment faire exactement en TP.

Bon à savoir

• structure de données du map() et du reduce() identiques

```
db.rawData.mapReduce(
function map() {
     emit(this.name, {
         benefits : this.benefits,
         entrances : this.entrances
     });
 },
 function reduce(key, values) {
   var totalBenefits = 0;
   var totalEntrances = 0;
    values.forEach(function (item) {
        totalBenefits += item.benefits;
        totalEntrances += item.entrances;
    });
    return {
        benefits : totalBenefits,
        entrances : totalEntrances
 }, options
```

Mise à jour de la table résultat

• Modification du paramètre out pouvant prendre l'objet suivant :

- action : Peut prendre les valeurs suivantes :
 - replace : Remplace tout le contenu de la collection du résultat par le contenu du mapReduce.
 - merge : Ajoute un résultat si la clé n'existe pas et écrase les clés existantes.
 - reduce : Fait comme le merge, sauf que si la clé existe,
 réapplique la fonction reduce sur les anciens et nouveaux résultats pour cette clé.
- collectionName : Collection contenant le résultat de la requête.
- db : Base de donnée où vous voulez créer la collection.

II - Les index

- 1. Les types d'index
- 2. Création d'un index
- 3. Les indexes de type text
- 4. Options des indexes

Les types d'index :

- simple field
- compound (plusieurs fields)
- multi key (plusieurs fields de sous collections)
- text
- hash
- geospatial

Création d'un index

Exemple:

```
db.test.createIndex({ name: 1 });
db.vendeurs.createIndex({ 'objectif.ca' : -1 });
```

- Créer un index sur le champ name dans la collection test avec un tri ascendant.
- Créer un index sur le champ ca du field objectif dans la collection vendeurs avec un tri descendant.

Text

```
db.collection.createIndex({
   name : "text",
   city : "text"
});
db.collection.createIndex({ "$**": "text" });
```

Le field \$** est un mot clé permetant de sélectionner tous les champs compatibles (objet courant, sous objet et sous collection) avec l'index Text.

Attention: Une collection ne peut avoir qu'un seul index de type texte.

Text

Permet l'utilisation de l'opérateur \$text dans une query :

```
db.collection.find({
    $text : {
        $search : "John Doe Ingénieur"
    }
});
```

Recherche dans tous les fields de l'index si les mots John , Doe ou Ingénieur existent. Si oui, retourne le résultat.

Depuis la version 3.2, les recherches avec \$text sont insensitives et les accents sont remplacés par la lettre de base. Les É, é, E, e, ... sont vu comme un e.

Les options des indexes

Les options sur les index sont les suivantes :

- unique
- partial (arrive avec la 3.2)
- collation (arrive avec la 3.4)
- TTL

Unique

```
db.collection.createIndex({ key : 1 }, { unique : true });
db.vendeur.createIndex({
   numSecu : 1,
   firstname : 1,
   lastname : 1
}, {
   unique : true
});
```

Pour le second exemple, on ne peut pas avoir 2x le même vendeur ayant à la fois le même numéro de sécu, nom et prénom.

Partial

Permet de donner un index uniquement aux documents répondant à la requête de l'index.

Index uniquement sur les champs cuisine et name les restaurants ayant une note supérieure à 5.

III - Optimisation et performances

- explain
- Règles de création d'un index
- Profiling
- ReplicaSet et Sharding

Le explain()

Permet de savoir comment une requête fonctionne selon 3 types :

- queryPlanner
- executionStats
- serverInfo

```
db.collection.find().explain('queryPlanner');
db.collection.find().explain('executionStats');
db.collection.find().explain('serverInfo');
```

queryPlanner

```
"queryPlanner" : {
   "plannerVersion" : <int>,
   "namespace" : <string>,
   "indexFilterSet" : <boolean>,
   "parsedQuery" : { ... },
   "winningPlan" : {
      "stage" : <STAGE1>,
      "inputStage" : {
         "stage" : <STAGE2>,
         "inputStage" : { ... }
   "rejectedPlans" : [
      <candidate plan 1>,
```

queryPlanner

Quelques fields importants:

- explain.queryPlanner.indexFilterSet : Un Booléen qui dit si oui ou non un index a été utilisé.
- explain.queryPlanner.winningPlan.stage : Nom dustage. Si jamais il a la valeur IXSCAN , vous retrouverez ensuite quels sont les indexs utilisés. dans inputStage ou inputStages

executionStats

```
"executionStats" : {
   "executionSuccess" : <boolean>,
   "nReturned" : <int>,
   "executionTimeMillis" : <int>,
   "totalKeysExamined" : <int>,
   "totalDocsExamined" : <int>,
   "executionStages" : { ... },
   "allPlansExecution" : [
      { <partial executionStats1> },
      { <partial executionStats2> },
```

executionStats

Quelques fields importants:

- explain.executionStats.nReturned : Nombre de documents retournés par la requête.
- explain.executionStats.executionTimeMillis : Temps de la requête
- explain.executionStats.totalKeysExamined : Nombre d'entrées d'index scannés
- explain.executionStats.totalDocsExamined : Nombre de documents scannés

Règles de création d'un index

- Trop d'indexes = ralentissement de l'écriture
- Identification des indexes avec explain()
- Compound index : champs indexés de gauche à droite
- Créer les indexes en background
- index multicolonnes, Règles du ESR (Equality Sort Range)

Identification des indexes

- 1. Faire son db.find({ /* ... */}).explain()
- 2. Verifier ratio documents retournés / documents examinés
- 3. Ajouter l'index correspondant à la requête
- 4. recommencer l'opération si ratio !== 1 ou trop éloigné

Background Index

- Création en arrière plan
- non bloquant
- ralentissements lors de la création moins importants

```
db.rawData.createIndex({
    name : 1
}, {
    background : true
}
```

Règles du ESR

- Optimisation des index :
 - i. fields de recherche
 - ii. fields de sort
 - iii. fields de range (\$gt, \$1t)

3 niveaux disponibles:

- 0 : aucun profiling au sein de la base de donnée
- 1 : collecte uniquement les requêtes lentes. Une requête est dite lente si elle dépasse les 100 ms d'exécution
- 2 : collecte tout de A à Z mais peut ralentir fortement la base de donnée selon le volume d'opérations.

```
db.setProfilingLevel(1);
```

Niveau intéressant : 1 couplé ensuite avec le explain() sur les requêtes lentes.

Toutes les requêtes sont stoquées dans la collection system.profile.

```
"op" : "query",
"ns" : "test.c",
"query" : {
  "find" : "c",
   "filter" : {
      "a" : 1
"keysExamined" : 2,
"docsExamined" : 2,
"cursorExhausted" : true,
"keyUpdates" : 0,
"writeConflicts" : 0,
"numYield" : 0,
"nreturned" : 2,
"responseLength" : 108,
"millis" : 0,
"execStats" : { ... }
```

Quelques champs utiles:

- op : Type d'opération (query , insert , ...)
- ns namespace de la forme <base de donnée>.<collection>.
- query : La requête exécutée.
- keysExamined : Combien d'index ont été scannés.
- docsExamined : Combien de documents ont été scannés.
- millis: Temps d'exécution
- execStats : Statistiques d'exécution. Ressemble beaucoup à ce que l'on a vu dans explain().

Retourner les 10 dernières requêtes lentes :

```
db.system.profile.find().limit(10).sort({ ts : -1 }).pretty()
```

Retourne les requêtes lentes d'une collection donnée :

```
db.system.profile.find({ ns : 'mydb.test' }).pretty()
```

Retourne les 5 événements les plus récents :

```
show profile
```

Autres optimisations possibles

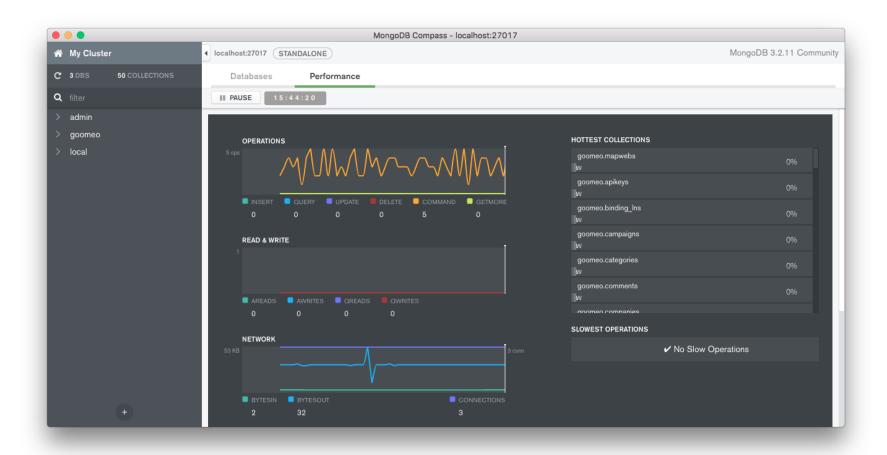
- Mongotop: Permet de savoir quelle est la vitesse de lecture/ecriture du serveur mongo.
- Mongostat : Fonctionne comme vmstat mais uniquement pour le seveur mongo (load average, nombre de processus en queue, ...).
- ReplicaSet : Reéplique les données sur x serveurs permettant d'éviter une coupure si un serveur tombe en panne
- Sharding: Obligatoirement couplé avec du ReplicaSet. Permet de scinder sur plusieurs pools de sharding une collection pour un accès plus rapide.

IV - MongoDB Compass

- Client MongoDB Officiel
- Administrer facilement son serveur MongoDB
- Monitorer en temps réel
- Afficher les requêtes lentes
- Voir et optimiser vos requêtes avec un explain visuel

• ...

IV - MongoDB Compass



Attention: La version Community Edition ne comprend pas la partie performance

V - MongoDB 3.6

- Publié en décembre 2017
- Améliore les jointures dans les aggregate
- Ajout des IP whitelist pour les règles de connexion
- Validation avec un schéma JSON des données
- Changement des streams
 - Partage en temps réel des modifications en BDD
- ...
- Liste complète : https://www.mongodb.com/mongodb-3.6